Höhere Mathematik für Informatiker 1

Rechnerarithmetik

Maschinenzahlen

Jede $x \in \mathbb{R}$ darstellbar als $x = m \cdot B^e$ mit Basis $B \in \mathbb{N}_{\geq 2}$, Mantisse $m \in \mathbb{R}$, Exponent $e \in \mathbb{Z}$.

Maschinenzahlen / Gleitpunktzahlen: n Stellen für m, l Stellen für e, Normalisierung $m_1 \neq 0$ (falls $x \neq 0$) $\Rightarrow$ eindeutige Darstellung:

$$M = \{x \in \mathbb{R} \mid x = \pm 0.m_1 ... m_n \cdot B^{e_{l-1} ... e_0 - \text{bias}}\} \cup \{0\}$$

mit $m_i, e_j \in \{0, ..., B-1\}$, $m_1 \neq 0$. Wert:

$$x = \sum_{i=1}^{n} m_i B^{e-i}, \quad e = \sum_{i=0}^{l-1} e_i B^i - \text{bias}$$

- **bias** $\in \mathbb{N}$ fix, so dass Wertebereich von e je zur Hälfte negativ/positiv; $e_{\min} \leq e \leq e_{\max}$
- **n-stellige Gleitpunktzahl zur Basis B**; $x \notin M$ wird gerundet
- Punkt um k Stellen nach links $\Rightarrow e + k$; nach rechts $\Rightarrow e - k$. Z. B. $(1011100.111)_2 = (0.1011100111)_2 \cdot 2^7$
- Ohne Normalisierung: Mantisse/Exponent nicht eindeutig ($0.0111 \cdot 2^4 = 1.11 \cdot 2^2 = ...$)
- Bsp.: $0.71537 \cdot 8^2 = 7 \cdot 8^1 + 1 \cdot 8^0 + 5 \cdot 8^{-1} + 3 \cdot 8^{-2} + 7 \cdot 8^{-3}$

IEEE-754 ($B = 2$)

	Bits	V	E	bias	M
single	32	1	8	127	23
double	64	1	11	1023	52

$$x = (-1)^V \cdot \left(\underbrace{1}_{\text{hidden bit}} . \underbrace{MMM...M}_{\text{fraction}} \right) \cdot 2^{(E...E) - \text{bias}}$$

- Normalisiert: führende Ziffer vor dem Punkt, immer 1 $\Rightarrow$ nicht gespeichert (**hidden bit**)
- `0 10000001 101000...` $= +1.101 \cdot 2^{129-127} = 6.5$
- `0 00000001 000...` $= 2^{-126} = x_{\min}$; subnormal `0 00000000 0...01` $= 2^{-149}$

Bereich

Maschinenzahlen **nicht gleichmässig verteilt** (dichter bei 0).

$$x_{\max} = B^{e_{\max}} - B^{e_{\max}-n} = (1 - B^{-n}) B^{e_{\max}}$$
$$x_{\min} = B^{e_{\min}-1} \quad \text{(kleinste pos. normalisierte)}$$

- **Overflow:** $|x| > x_{\max}$ $\rightarrow$ Abbruch (IEEE: `inf`)
- **Underflow:** $0 < |x| < x_{\min}$ $\rightarrow$ mit 0 weiterrechnen
- **Subnormale Zahlen** ($m_1 = 0$ erlaubt): füllen $(0, x_{\min})$ bis $B^{e_{\min}-n}$
- Vorteil ggü. Ganz-/Festpunktsystem: bei gleichem Speicher viel grösserer Bereich, aber variabler Abstand

Rundungsfehler und Maschinengenauigkeit

Näherung $\tilde{x}$ zu exaktem x:

- **Absoluter Fehler:** $|\tilde{x} - x|$
- **Relativer Fehler** ($x \neq 0$): $\frac{|\tilde{x}-x|}{|x|}$

Runden: $\tilde{x} = \text{rd}(x)$ = Maschinenzahl mit minimalem $|\text{rd}(x) - x|$ (besser als Abschneiden). Für n-stellige Mantisse, B gerade:

$$|\text{rd}(x) - x| \leq 0.\underbrace{0...0}_{n}\frac{B}{2} \cdot B^e = \frac{B}{2} \cdot B^{e-n-1}$$

***n*-stellige Gleitpunktarithmetik:** jede Operation $(+, -, \cdot, /)$ auf $n+1$ Stellen genau, Ergebnis auf n Stellen gerundet. **Jedes Zwischenergebnis** wird gerundet $\rightarrow$ Fehler pflanzen sich fort, Reihenfolge relevant.

Faustregel: Summanden nach aufsteigenden Beträgen sortiert addieren.

Maschinengenauigkeit

$\text{eps} := \frac{B}{2} \cdot B^{-n} = \frac{1}{2} \cdot B^{1-n}$ Entspricht maximalem relativer Rundungsfehler: $\frac{|\text{rd}(x)-x|}{|x|} \leq \text{eps}$

- Grösste pos. Maschinenzahl mit $1 + \text{eps} = 1$ (gerundet)
- **Achtung:** IEEE/Python/Matlab: `eps` = Abstand von 1 zur nächstgrösseren Maschinenzahl $= 2 \cdot \text{eps}_{\text{Def}}$
- $\text{eps} \neq x_{\min}$ ($x_{\min}$ viel kleiner)
- IEEE double: $n = 53$ (hidden bit) $\Rightarrow \text{eps} = 2^{-53}$

Fehlerfortpflanzung / Kondition

$\tilde{x} = x + \Delta x$; Taylor um x, Terme $(\Delta x)^k, k \geq 2$ vernachlässigt ($\Delta x \ll 1$):

$$f(\tilde{x}) - f(x) \approx f'(x)(\tilde{x} - x)$$

- **Absoluter Fehler:**

$$\underbrace{|f(\tilde{x}) - f(x)|}_{\text{abs. Fehler } f(x)} \approx |f'(x)| \cdot \underbrace{|\tilde{x} - x|}_{\text{abs. Fehler } x}$$

- **Relativer Fehler:**

$$\underbrace{\frac{|f(\tilde{x}) - f(x)|}{|f(x)|}}_{\text{rel. Fehler } f(x)} \approx \underbrace{\frac{|f'(x)| \cdot |x|}{|f(x)|}}_{K(x)} \cdot \underbrace{\frac{|\tilde{x} - x|}{|x|}}_{\text{rel. Fehler } x}$$

Konditionszahl von $y = f(x)$ an der Stelle x:

$$K(x) := \frac{|f'(x)| \cdot |x|}{|f(x)|}$$

Faktor, um den sich der rel. Fehler ungefähr vergrössert. Klein $\Rightarrow$ **gut konditioniert**; gross $\Rightarrow$ **schlecht konditioniert** (ill posed).

- Abs. Fehler wächst falls $|f'(x)| > 1$, sonst nicht (z. B. sin: $|\cos x| \leq 1$)
- Fehlerquelle egal (Rundung, Messung, …)
- $f(x) = x^2$: $K = 2$ (noch gut)
- Bsp. schlecht: Nullstellen des Wilson-Polynoms $\prod_{k=1}^{20}(x-k)$ aus Koeffizienten; Störung $\sim 10^{-7}$ $\rightarrow$ Nullstellen ändern sich um ~ 1 (teils komplex)

Auslöschung

Summation $f(x) = x + c$: $f'(x) = 1$,

$$K(x) = \frac{|x|}{|x + c|}$$

- x, c gleiches Vorzeichen: $K \leq 1$ (gut)
- Entgegengesetztes Vorzeichen, $|x| \approx |c|$: $|x + c|$ klein $\Rightarrow K$ gross
- **Auslöschung:** Subtraktion ungefähr gleich grosser, fehlerbehafteter Zahlen + anschliessende Normalisierung $\rightarrow$ grosser rel. Fehler
- Bsp. 5-stellig: $x_1 = 123.454 \cdot 10^9$, $x_2 = 123.446 \cdot 10^9$ $\rightarrow$ $\tilde{x}_1 = \tilde{x}_2 = 0.12345 \cdot 10^{12}$, $\tilde{x}_1 - \tilde{x}_2 = 0$ statt $8 \cdot 10^6$

Nullstellenprobleme

Gesucht: Näherung für Nullstelle $\overline{x}$ von stetigem $f : \mathbb{R} \rightarrow \mathbb{R}$. $g(x) = h(x) \Leftrightarrow f(x) := g(x) - h(x) = 0$.
Vorab klären: Existiert eine Nullstelle, wo? Mehrere, welche gesucht?
Resultate i. d. R. als $\pm m_1.m_2m_3m_4m_5 \cdot 10^{\pm e}$, $m_1 \neq 0$.

Fixpunktiteration

- **Fixpunktgleichung:** $F(x) = x$
- **Fixpunkt:** Lösung $\overline{x}$ mit $F(\overline{x}) = \overline{x}$
- $f(x) = 0$ in Form $F(x) = x$ bringen (viele Möglichkeiten), Lösungsmenge darf sich **nicht** ändern. Z. B. $x^3 - x + 0.3 = 0$: $F(x) = x^3 + 0.3$ oder $F(x) = \sqrt[3]{x - 0.3}$
- Graphisch: Schnittpunkte von $y = F(x)$ und $y = x$

Fixpunktiteration von $F : [a, b] \rightarrow \mathbb{R}$ zum Startwert $x_0 \in [a, b]$:

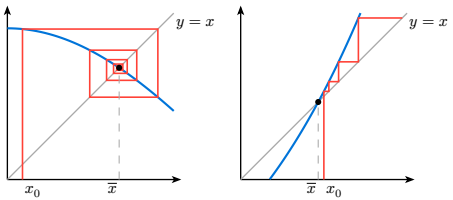
$$x_{n+1} = F(x_n), \quad n = 0, 1, 2, ...$$

1 Funktionsauswertung pro Schritt. Verschiedene F zum selben Problem können unterschiedlich konvergieren.

Anziehend / abstossend

F mit stetigem F', $\overline{x} \in [a, b]$ Fixpunkt:

- **Anziehender Fixpunkt:** Ist $|F'(\overline{x})| < 1$, so konvergiert $x_n \rightarrow \overline{x}$, falls der Startwert x_0 nahe genug bei $\overline{x}$ liegt; (je kleiner $|F'(\overline{x})|$, desto schneller)
- **Abstossender Fixpunkt:** Ist $|F'(\overline{x})| > 1$, so konvergiert x_n für kein $x_0 \neq \overline{x}$.



anziehend: $F(x) = \cos x$ abstossend: $F(x) = x^3 + 0.3$

Banachscher Fixpunktsatz

Sei $F : [a, b] \rightarrow [a, b]$ (bildet $[a, b]$ auf sich ab) und $\exists \alpha \in (0, 1)$ mit

$$|F(x) - F(y)| \leq \alpha \, |x - y| \quad \forall x, y \in [a, b]$$

(Lipschitz-stetig, kontraktiv; α = Lipschitz-Konstante). Dann:

- F hat **genau einen** Fixpunkt $\overline{x}$ in $[a, b]$
- $x_{n+1} = F(x_n)$ konvergiert gegen $\overline{x}$ für **alle** $x_0 \in [a, b]$
- Fehlerabschätzungen:

$$|x_n - \overline{x}| \leq \frac{\alpha^n}{1 - \alpha} \, |x_1 - x_0| \qquad \text{a-priori}$$
$$|x_n - \overline{x}| \leq \frac{\alpha}{1 - \alpha} \, |x_n - x_{n-1}| \quad \text{a-posteriori}$$

α = grösste Steigung von F auf $[a, b]$: $\alpha = \max_{x \in [a,b]} |F'(x)|$. Intervall eng um $\overline{x} \Rightarrow \alpha \approx |F'(\overline{x})|$.

Vorgehen:

1. $F([a, b]) \subseteq [a, b]$ prüfen (bei monotonem F: $F(a), F(b) \in [a, b]$)
2. $\alpha = \max_{[a,b]} |F'(x)| < 1$ bestimmen
3. Iterationen für Toleranz tol (a-priori nach n aufgelöst):

$$n \geq \frac{\ln\left(\frac{\text{tol} \cdot (1-\alpha)}{|x_1 - x_0|}\right)}{\ln(\alpha)}$$

Newton-Verfahren

Nullstelle der Tangente $g(x) = f(x_n) + f'(x_n)(x - x_n)$ in x_n als neue Näherung (f stetig differenzierbar, $f'(x_n) \neq 0$):

$$x_{n+1} = x_n - \frac{f(x_n)}{f'(x_n)}$$

- Startwert nahe bei Nullstelle wählen; ungeeignet, wo Tangente fast parallel zur x-Achse
- **Hinreichende Konvergenzbedingung** auf $[a, b]$ (enthält alle x_n und $\overline{x}$), i. d. R. mind. für x_0 prüfen:

$$\left| \frac{f(x) \cdot f''(x)}{[f'(x)]^2} \right| < 1$$

- $f(x) = x^2 - A$ ergibt Heron-Verfahren: $x_{n+1} = \frac{1}{2}\left(x_n + \frac{A}{x_n}\right)$

Vereinfachtes Newton-Verfahren

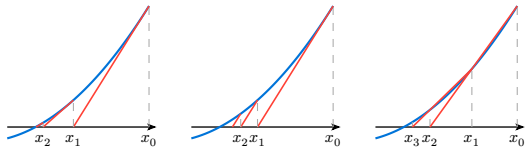
Ableitung nur einmal bei x_0 berechnen (konvergiert langsamer):

$$x_{n+1} = x_n - \frac{f(x_n)}{f'(x_0)}$$

Sekantenverfahren

Ableitung durch Sekantensteigung ersetzt; 2 Startwerte x_0, x_1, keine Ableitung nötig, konvergiert langsamer:

$$x_{n+1} = x_n - \frac{x_n - x_{n-1}}{f(x_n) - f(x_{n-1})} \cdot f(x_n), \quad n = 1, 2, ...$$



Newton (Tangenten) Vereinf. Newton (parallel) Sekanten

Konvergenzordnung

Sei (x_n) gegen $\overline{x}$ konvergent. Das Verfahren hat **Konvergenzordnung** $q \geq 1$, wenn $\exists c > 0$ mit

$$|x_{n+1} - \overline{x}| \leq c \cdot |x_n - \overline{x}|^q \quad \forall n$$

Für $q = 1$ zusätzlich $c < 1$. $q = 1$: **linear**, $q = 2$: **quadratisch** (z. B. $c = 1$, Fehler $10^{-2} \to 10^{-4} \to 10^{-8}$).

Verfahren (einfache Nullstelle)	q
Newton	2
Vereinfachtes Newton	1
Sekantenverfahren	$\frac{1+\sqrt{5}}{2} \approx 1.618$

Fehlerabschätzung

Nullstellensatz von Bolzano: $f : [a, b] \to \mathbb{R}$ stetig mit $f(a) \leq 0 \leq f(b)$ oder $f(a) \geq 0 \geq f(b) \Rightarrow f$ hat Nullstelle in $[a, b]$. Insb. $f(a) \cdot f(b) < 0 \Rightarrow$ mind. eine Nullstelle.

Für Näherung x_n einer Nullstelle ξ **ungerader Ordnung** (Schnitt-, kein Berührungspunkt) und Toleranz $\varepsilon > 0$:

$$f(x_n - \varepsilon) \cdot f(x_n + \varepsilon) < 0 \quad \Rightarrow \quad |x_n - \xi| < \varepsilon$$

Für jedes iterative Verfahren anwendbar.

Abbruchkriterien (zusätzlich, z. B. bei Berührungspunkten / schlechter Kondition):

- Max. Anzahl Iterationen $N_{\max}$
- $|f(x_n)| < \varepsilon$ oder $|x_{n+1} - x_n| < \varepsilon$ (nur notwendig, **keine Garantie** für Nähe zur Nullstelle)

By Justin Iven Müller (2026)
github.com/JustinIven/zhaw-cheatsheets