Stochastik und Statistik

Deskriptive Statistik

- **Deskriptiv:** Beschreibung, Darstellung, Kenngrössen, Datenvalidierung
- **Explorativ:** Suche nach Strukturen/Besonderheiten
- **Induktiv (schliessend):** mit W'keitsrechnung über Daten hinaus schliessen

Begriffe

Merkmalsträger	Statistische Einheit, an der beobachtet wird
Grundgesamtheit	Alle Einheiten, über die man Aussagen will (endlich/ unendlich, real/hypothetisch)
Vollerhebung	Jede Einheit der Grundgesamtheit wird erfasst
Stichprobe	Untersuchte Teilmenge, repräsentativ; Zufallsstichprobe: jede Einheit gleiche Chance
Stichprobengrösse n	Anzahl Einheiten in der Stichprobe
Merkmal (Variable)	Beobachtete Grösse $X : \Omega \to \mathbb{R}$, $x_i = X(\omega_i)$
Ausprägung	Möglicher Wert eines Merkmals
Urliste	Stichprobenwerte $x_1, ..., x_n$ in Erhebungsreihenfolge

Merkmalstypen (Messniveau)

Kategoriell (qualitativ)	Nominal	Nur Kategorien, keine Ordnung (Partei, Tel.-Nr.)
	Ordinal	Ordnung/ Rangierung möglich (schlecht/mittel/ gut)
Metrisch (quantitativ)	Diskret	Endlich/abzählbar viele Werte (Würfel)
	Stetig	Alle Werte in reellem Intervall (Laufzeit)

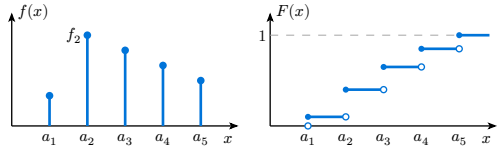
Darstellung: kategoriell → Säulen-/Stabdiagramm; metrisch → zusätzlich Histogramm (Klassen).

Häufigkeiten (univariat)

Stichprobe $x_1, ..., x_n$ mit m verschiedenen Werten $a_1 < ... < a_m$:

- **Absolute Häufigkeit:** h_i = Anzahl $x_j = a_i$, $\sum h_i = n$
- **Relative Häufigkeit:** $f_i = \frac{h_i}{n}$, $\sum f_i = 1$
- **PMF** (empirische Dichte, diskret): $f : \mathbb{R} \to [0, 1]$, $f(x) = 0$ für $x \neq a_i$
- **Abs. Summenhäufigkeit:** $H(x) = \sum_{i:a_i \leq x} h_i$ (Anzahl $x_i \leq x$)
- **CDF:** $F(x) = \frac{H(x)}{n} = \sum_{i:a_i \leq x} f_i$

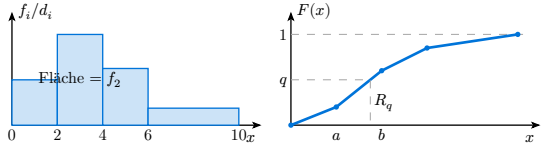
Eigenschaften CDF: $0 \leq F \leq 1$, monoton wachsend, rechtsseitig stetige Treppenfunktion, springt bei a_i um f_i.
Anteil in $a < x_i \leq b$: $F(b) - F(a)$; Anteil $> a$: $1 - F(a)$.



Klassierte Daten

Bei grossen Stichproben stetiger Merkmale: Bereich in angrenzende Klassen $c_i = [a, b[$ mit Breite $d_i = b - a$ einteilen; obere Grenze gehört zur nächsten Klasse. h_i, f_i: abs./rel. Häufigkeit der Klasse c_i.

- **Histogramm:** Häufigkeit = **Fläche** des Rechtecks (nicht Höhe!)
- Abs. Dichte (Höhe): $\frac{h_i}{d_i}$, rel. Dichte **PDF**: $\frac{f_i}{d_i}$
- **CDF:** $F(x) = \int_{-\infty}^{x} f(t)\,\mathrm{d}t$ → stetiger Polygonzug; an rechter Klassengrenze = kumulierte f_i
- **Faustregeln:** gleich breite Klassen; 5–20 Klassen, nicht wesentlich mehr als $\sqrt{n}$
- Säulenhöhe schwankt um ca. Wert $\pm 2\sqrt{\text{Wert}}$ → Gipfel nur echt, wenn sich diese Intervalle nicht überschneiden



Quantile

Geordnet: $x_{[1]} \leq ... \leq x_{[n]}$ (Position = Rang). $q \in (0, 1)$: Anteil.
Def.: R_q ist q-Quantil, falls Anteil $x_i \leq R_q$ mindestens q und Anteil $x_i \geq R_q$ mindestens $1 - q$.
0.25, 0.5, 0.75-Quantil = 1., 2., 3. **Quartil** (Q_1, Q_2, Q_3); $q \cdot 100$-tes **Perzentil**.
Berechnung (nicht klassiert):

- nq ganzzahlig: $R_q = \frac{1}{2}\left(x_{[nq]} + x_{[nq+1]}\right)$
- nq nicht ganzzahlig: $R_q = x_{[\lceil nq \rceil]}$ ($\lceil \cdot \rceil$: aufrunden)

Aus CDF: q trifft Plateau ($F(a) = q$) → $R_q = \frac{1}{2}(a + b)$, b nächster Wert; q trifft Sprung → $R_q = a$.

Median: $x_{\text{med}} = \begin{cases} x_{[\frac{n+1}{2}]} & n \text{ ungerade} \\ \frac{1}{2}\left(x_{[\frac{n}{2}]} + x_{[\frac{n}{2}+1]}\right) & n \text{ gerade} \end{cases}$

Interquartilsabstand: IQR $= Q_3 - Q_1$ (Streumass zum Median, enthält mittlere 50%)

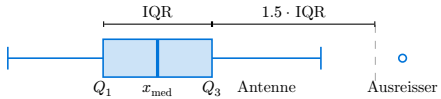
Klassiert: $R_q = F^{-1}(q)$ (lineare Interpolation, siehe Grafik oben). Klasse $[a, b[$ mit $F(a) \leq q \leq F(b)$:

$$R_q = a + \frac{(b - a)(q - F(a))}{F(b) - F(a)}$$

numpy `quantile` kann abweichen (bei grossem n unerheblich).

Boxplot

- **Box:** von Q_1 bis Q_3, Strich bei Median
- **Untere Antenne:** kleinster Wert mit Abstand $\leq 1.5 \cdot$ IQR von Q_1
- **Obere Antenne:** grösster Wert mit Abstand $\leq 1.5 \cdot$ IQR von Q_3
- **Ausreisser:** alle Werte ausserhalb Box + Antennen (einzeln eingezeichnet)



Lagemasse

- **Modus** x_{mod}: häufigster Wert (nicht eindeutig); klassiert: Mitte der Klasse mit grösstem f_i
- **Arithm. Mittel:** $\overline{x} = \frac{1}{n}\sum_{i=1}^{n} x_i = \frac{1}{n}\sum_{i=1}^{m} a_i h_i = \sum_{i=1}^{m} a_i f_i$
- **Median** x_{med}: teilt Stichprobe in zwei gleich grosse Hälften

Streuungsmasse

Empirische Varianz:

$$\tilde{s}^2 = \frac{1}{n}\sum_{i=1}^{n}(x_i - \overline{x})^2 = \frac{1}{n}\sum_{i=1}^{m} h_i(a_i - \overline{x})^2 = \left(\sum_{i=1}^{m} a_i^2 f_i\right) - \overline{x}^2$$

Standardabweichung: $\tilde{s} = \sqrt{\tilde{s}^2}$ (gleiche Einheit wie Daten)

Korrigiert (Schätztheorie, Faktor $n - 1$):

$$s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \overline{x})^2 = \frac{n}{n-1}\tilde{s}^2, \quad s = \sqrt{s^2}$$

Klassiert: Mittel und Varianz mit Klassenmitten als a_i berechnen.

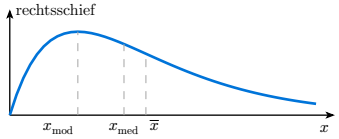
- **Tschebyscheff:** mind. 75% der Werte in $\overline{x} \pm 2s$
- **Annähernd normalverteilt:** ca. 68% in $\overline{x} \pm s$, ca. 95% in $\overline{x} \pm 2s$

Python: `np.var(x)` $= \tilde{s}^2$, `np.var(x, ddof=1)` $= s^2$ (analog `np.std`)

Form der Verteilung

Rechtsschief (linkssteil)	$x_{\text{mod}} < x_{\text{med}} < \overline{x}$
Symmetrisch	$x_{\text{mod}} = x_{\text{med}} = \overline{x}$
Linksschief (rechtssteil)	$x_{\text{mod}} > x_{\text{med}} > \overline{x}$

Ein Maximum: **unimodal**; zwei/mehrere: **bimodal** bzw. **multimodal**.



Kombinatorik

- **Fakultät:** $0! = 1$, $n! = n \cdot (n-1)!$
- **Binomialkoeffizient** (k aus n, n tief k), $0 \leq k \leq n$:

$$\binom{n}{k} = \frac{n!}{(n-k)! \cdot k!}$$

Anzahl Auswahlen von k aus n unterscheidbaren Objekten (ohne Reihenfolge, ohne Wiederholung)

Vier Grundtypen (Auswahl k aus n)

- **Variation:** Reihenfolge spielt eine Rolle
- **Kombination:** Reihenfolge spielt keine Rolle

	Mit Wiederholung	**Ohne Wiederholung**
Variation	n^k	$\frac{n!}{(n-k)!}$
Kombination	$\binom{n+k-1}{k}$	$\binom{n}{k}$

Typische Techniken

- **Produktregel:** unabhängige Teilauswahlen multiplizieren, z. B. 6 aus 8 Frauen und 5 aus 12 Männern: $\binom{8}{6}\binom{12}{5}$
- **Ersatzproblem:** äquivalentes, einfacher abzählbares Problem (Bijektion)
- **Kombination mit Wdh.** (Kreuze/Striche): k Kreuze X + $(n-1)$ Trennstriche I auf $n + k - 1$ Stellen verteilen → $\binom{n+k-1}{k} = \binom{n+k-1}{n-1}$
- **Mind. 1 pro Empfänger:** k gleiche Objekte auf n Personen, jeder ≥ 1: zuerst je 1 verteilen, Rest $k - n$ mit Wdh. → $\binom{k-1}{k-n}$
- **Runder Tisch:** Drehung egal → eine Person fixieren, Rest $(n-1)!$ anordnen; zwei Personen nebeneinander: $2 \cdot (n-2)!$
- **Teilmengen/Gruppen:** Bitmuster (1 = gewählt) → 2^n Teilmengen ($|\mathcal{P}(M)| = 2^n$), nicht-leer: $2^n - 1$

Eigenschaften Binomialkoeffizient

1. **Leere Menge:** $\binom{n}{0} = 1$
2. **Symmetrie:** $\binom{n}{k} = \binom{n}{n-k}$
3. **Pascal'sches Dreieck:** $\binom{n+1}{k+1} = \binom{n}{k} + \binom{n}{k+1}$
4. **Summe:** $\sum_{k=0}^{n}\binom{n}{k} = 2^n$
5. **Binomischer Lehrsatz** ($a, b \in \mathbb{C}$):

$$(a+b)^n = \sum_{k=0}^{n}\binom{n}{k}a^k b^{n-k}$$

Elementare Wahrscheinlichkeitsrechnung

Diskrete Wahrscheinlichkeitsräume

Zufallsexperiment: beliebig oft unter gleichen Bedingungen wiederholbar; mehrere sich gegenseitig ausschliessende, vorab bekannte Ergebnisse; Ergebnis zufallsbedingt.

Ergebnisraum Ω	Menge aller möglichen, sich gegenseitig ausschliessenden Ergebnisse; **diskret**: endlich oder abzählbar unendlich
Zähldichte ρ	$\rho : \Omega \to [0,1]$ mit $\sum_{\omega\in\Omega} \rho(\omega) = 1$
Ereignis A	Teilmenge $A \subseteq \Omega$; tritt ein, wenn Ergebnis $\in A$. $\{\}$ = unmögliches, Ω = sicheres Ereignis
Ereignisraum 2^Ω	Potenzmenge von Ω (alle Ereignisse), $\lvert 2^\Omega\rvert = 2^{\lvert\Omega\rvert}$
W'keitsmass P	$P : 2^\Omega \to [0,1]$, $P(M) = \sum_{\omega\in M} \rho(\omega)$
Diskreter W'raum	(Ω, P) mit diskretem Ω
Laplace-Raum	ρ konstant (Gleichverteilung): $P(M) = \frac{\lvert M\rvert}{\lvert\Omega\rvert}$

Eigenschaften:

1. $P(\{\}) = 0$
2. $P(\Omega) = 1$
3. $P(\Omega \setminus A) = 1 - P(A)$
4. $P(A \cup B) = P(A) + P(B) - P(A \cap B)$
5. σ-Additivität: $P(A_1 \cup A_2 \cup ...) = P(A_1) + P(A_2) + ...$ für paarweise disjunkte A_i

Zufallsvariablen

- **Zufallsvariable:** Funktion $X : \Omega \to \mathbb{R}$; $X = x$ steht für Ereignis $\{\omega \in \Omega \mid X(\omega) = x\}$
- **Dichtefunktion (PMF):**
$$f : \mathbb{R} \to [0,1], \quad f(x) = P(X = x)$$
- **Kumulative Verteilungsfunktion (CDF):**
$$F : \mathbb{R} \to [0,1], \quad F(x) = P(X \leq x)$$

Eigenschaften:

1. $$\sum_{x=-\infty}^{\infty} f(x) = 1, \quad F(z) = \sum_{x=-\infty}^{z} f(x)$$
2. $$\lim_{x\to\infty} F(x) = 1, \quad \lim_{x\to-\infty} F(x) = 0$$
3. Monotonie:
$$x \leq y \Rightarrow F(x) \leq F(y)$$
4. Sprunghöhe:
$$f(x) = F(x) - \lim_{y\to x^-} F(y)$$
5. $$P(a < X \leq b) = F(b) - F(a)$$
$$P(a \leq X \leq b) = F(b) - \lim_{x\to a^-} F(x)$$
6. $$P(X > b) = 1 - F(b), \quad P(X \geq b) = 1 - \lim_{x\to b^-} F(x)$$

Kenngrössen

Lagemass: Zentrum; **Streumass:** Abweichung vom Zentrum. Existieren nicht für jede Verteilung.

- **Erwartungswert:** $\mu = E(X) = \sum_{x\in\mathbb{R}} P(X = x) \cdot x$
- **Varianz:** $\sigma^2 = V(X) = \sum_{x\in\mathbb{R}} P(X = x) \cdot (x - E(X))^2$ (Einheit²)
- **Standardabweichung:** $\sigma = S(X) = \sqrt{V(X)}$ (Einheit wie X)

Rechenregeln ($\alpha, \beta \in \mathbb{R}$):

1. Linearität:
$$E(X + Y) = E(X) + E(Y), \quad E(\alpha X) = \alpha E(X)$$
2. Verschiebungssatz:
$$V(X) = E(X^2) - E(X)^2 = \left(\sum_{x\in\mathbb{R}} P(X = x) \cdot x^2\right) - E(X)^2$$
3. $$V(\alpha X + \beta) = \alpha^2 \cdot V(X)$$

Tschebyscheff (gilt für **jede** Verteilung): W'keit, um mind. $k > 0$ von $E(X)$ abzuweichen, ist höchstens $\frac{S(X)^2}{k^2}$.

$$P(\lvert X - E(X)\rvert \geq k) \leq \frac{S(X)^2}{k^2}$$

$$P(\lvert X - E(X)\rvert < k) \geq 1 - \frac{S(X)^2}{k^2}$$

Mit $k = c \cdot S(X)$: mind. $1 - \frac{1}{c^2}$ der Werte liegen in $E(X) \pm c \cdot S(X)$.

Anteil in $E(X) \pm cS(X)$	$c = 1$	$c = \sqrt{2}$	$c = 2$
Tschebyscheff	–	$\geq 50\%$	$\geq 75\%$
Normalverteilt	$\approx 68\%$		$\approx 95\%$

By Justin Iven Müller (2026)
github.com/JustinIven/zhaw-cheatsheets