Theoretische Informatik

Alphabete, Wörter und Sprachen

Alphabet

Ein Alphabet ist eine endliche, nichtleere Menge von Symbolen. Bsp.:

$$\Sigma = \{a, b, c\}, \quad \Sigma_{\text{bool}} = \{0, 1\}, \quad \Sigma_{\text{lat}} = \{a, b, c \cdots, z\}$$

Wörter

Ein Wort über einem Alphabet ist eine endliche Folge von Symbolen aus diesem Alphabet. Das leere Wort wird mit ε bezeichnet.

$$w = (x_1, x_2, \ldots, x_n), \quad x_i \in \Sigma, \quad n \in \mathbb{N}$$

Die Länge eines Wortes w ist die Anzahl der Symbole, also $|w| = n$. Die absolute Häufigkeit eines Symbols a in einem Wort w wird mit $|w|_a$ bezeichnet. Zusätzlich gilt:

$$|\varepsilon| = |\varepsilon|_a = 0, \quad a \in \Sigma$$

Spiegelung und Palindrome

Mit w^R wird das Spiegelwort von w bezeichnet, also die Umkehrung der Symbolfolge.

$$w^R = (x_1, x_2, \ldots, x_n)^R = (x_n, x_{n-1}, \ldots, x_1)$$

Wenn $w = w^R$ gilt, dann ist w ein Palindrom.

Wörter der Länge k

Die Menge aller Wörter der Länge k über einem Alphabet Σ wird mit Σ^k bezeichnet:

$$\Sigma^k = \{w \in \Sigma^* \mid |w| = k\}$$

Unabhängig von Σ gilt stets $\Sigma^0 = \{\varepsilon\}$.

Kleenesche Hülle

Die Menge aller Wörter über einem Alphabet Σ wird mit Σ^* bezeichnet:

$$\Sigma^* = \bigcup_{k \geq 0} \Sigma^k$$

Die Menge aller nichtleeren Wörter über Σ wird mit Σ^+ bezeichnet:

$$\Sigma^+ = \Sigma^* \setminus \{\varepsilon\}$$

Teilwortrelationen

Infix v ist Infix von $w \iff$ Es existieren $x, y \in \Sigma^*$ mit $w = xvy$.

Präfix v ist Präfix von $w \iff$ Es existiert $y \in \Sigma^*$ mit $w = vy$.

Suffix v ist Suffix von $w \iff$ Es existiert $x \in \Sigma^*$ mit $w = xv$.

Man spricht von einem *echten* Infix/Präfix/Suffix, wenn $v \neq w$ gilt.

Konkatination

Die Konkatenation von zwei Wörtern x und y ist die Aneinanderreihung der Symbole von x gefolgt von den Symbolen von y:

$$x \circ y = xy = (x_1, x_2, \ldots, x_n, y_1, y_2, \ldots, y_m)$$

Die Länge der Konkatenation ist die Summe der Längen der beiden Wörter:

$$|xy| = |x| + |y|$$

Die Konkatenation mit dem leeren Wort ε hat keine Auswirkung auf das Wort:

$$w\varepsilon = \varepsilon w = w$$

Wortpotenzen

Die n-te Potenz eines Wortes x wird für alle $n \in \mathbb{N}$ definiert als

$$x^0 := \varepsilon$$
$$x^{n+1} := x^n x$$

Die Potenzierung mit der Kleeneschen Hülle ergibt die gleiche Menge:

$$(A^*)^* = A^*$$

Sprache

Eine Teilmenge $L \subseteq \Sigma^*$ von Wörtern heisst Sprache über dem Alphabet Σ. Es gelten die folgenden Eigenschaften:

- $\{\} = \emptyset$ ist die leere Sprache für jedes Alphabet Σ.
- $\{\varepsilon\}$ ist die Sprache, die nur das leere Wort enthält, für jedes Alphabet Σ.
- Σ^* ist die Sprache aller Wörter über Σ.

Konkatenation

Die Konkatenation von Sprachen A und B ist definiert als die Menge aller Konkatenationen von Wörtern aus A mit Wörtern aus B:

$$AB = \{uv \mid u \in A, v \in B\}$$

Die Konkatenation von Sprachen ist assoziativ, aber im Allgemeinen nicht kommutativ:

$$(AB)C = A(BC), \quad AB \neq BA$$

Ist A eine Sprache über Σ und B eine Sprache über Γ, so ist AB eine Sprache über $\Sigma \cup \Gamma$.

Kleenesche Hülle

Die Kleenesche Hülle A^* einer Sprache A ist definiert als die Vereinigung aller Potenzen von A:

$$A^* = \bigcup_{k \geq 0} A^k$$

Dabei ist $A^0 = \{\varepsilon\}$ und $A^{k+1} = A^k A$. Die Kleenesche Hülle erfüllt die Eigenschaft:

$$(A^*)^* = A^*$$

Entscheidungsproblem

Sei eine Sprache $L \subseteq \Sigma^*$ gegeben. Das Entscheidungsproblem für L besteht darin, für ein beliebiges Wort $x \in \Sigma^*$ zu entscheiden, ob x in L enthalten ist oder nicht:

$$x \in \Sigma^* \mapsto \begin{cases} \text{JA} & \text{wenn } x \in L, \\ \text{NEIN} & \text{wenn } x \notin L. \end{cases}$$

Reguläre Ausdrücke (RA)

Reguläre Ausdrücke sind ein formale Sprache zur endlichen Beschreibung (möglicherweise unendlicher) Sprachen über einem Alphabet Σ.

Syntax

Die Menge RA_Σ der regulären Ausdrücke über Σ ist induktiv definiert durch:

- $\varnothing, \varepsilon \in \text{RA}_\Sigma$
- $\Sigma \subset \text{RA}_\Sigma$
- $R \in \text{RA}_\Sigma \Rightarrow (R^*) \in \text{RA}_\Sigma$
- $R, S \in \text{RA}_\Sigma \Rightarrow (RS) \in \text{RA}_\Sigma$
- $R, S \in \text{RA}_\Sigma \Rightarrow (R \mid S) \in \text{RA}_\Sigma$

Die Menge RA_Σ der regulären Ausdrücke über dem Alphabet Σ ist eine Sprache über dem Alphabet $\Sigma \cup \{\varepsilon, \varnothing, (,), ^*, |\}$.

Abkürzungen

$$R^+ := RR^*$$
$$R? := (R \mid \varepsilon)$$
$$[R_1, \ldots, R_k] := R_1 \mid \cdots \mid R_k$$

Semantik

Jedem regulären Ausdruck R wird eine Sprache $L(R)$ zugeordnet:

$$\begin{aligned} L(\varnothing) &= \emptyset \\ L(\epsilon) &= \{\varepsilon\} \\ L(a) &= \{a\} \quad \text{für } a \in \Sigma \\ L(R^*) &= L(R)^* \\ L(RS) &= L(R)L(S) \\ L(R \mid S) &= L(R) \cup L(S) \end{aligned}$$

Eine Sprache $A \subseteq \Sigma^*$ heisst *regulär*, falls es einen regulären Ausdruck R mit $A = L(R)$ gibt.

Rechenregeln

Fürjedes Alphabet Σ und alle regulären Ausdrücke $R, S, T \in \text{RA}_\Sigma$ gelten die folgenden Identitäten:

$$\begin{aligned} L(R \mid S) &= L(S \mid R) \\ L(R \mid (S \mid T)) &= L((R \mid S) \mid T) \\ L(R(S \mid T)) &= L(RS \mid RT) \\ L(R \mid R) &= L(R) \\ L(R(ST)) &= L((RS)T) \\ L((R^*)^*) &= L(R^*) \end{aligned}$$

Endliche Automaten

Grundidee

Endliche Automaten (EA) sind speicherbeschränkte Berechnungsmodelle zur Erkennung formaler Sprachen. Der einzige interne Speicher ist der aktuelle Zustand. Ein Eingabewort wird sequenziell gelesen; Akzeptanz wird über Endzusände entschieden.

Deterministische endliche Automaten

Ein deterministischer endlicher Automat (DEA) ist ein Tupel

$$M = (Q, \Sigma, \delta, q_0, F)$$

mit

- endlicher Zustandsmenge Q,
- Alphabet Σ,
- totaler Übergangsfunktion $\delta : Q \times \Sigma \to Q$,
- Startzustand $q_0 \in Q$,
- Endzustandsmenge $F \subseteq Q$.

Konfigurationen

Eine Konfiguration ist ein Paar

$$(q, w) \in Q \times \Sigma^*$$

mit aktuellem Zustand q und Restwort w.

Berechnungsschritte

Die Ein-Schritt-Relation ist definiert durch

$$(q, w) \vdash_M (p, x)$$

genau dann, wenn $w = ax$ mit $a \in \Sigma$ und $\delta(q, a) = p$. Die reflexiv-transitive Hülle wird mit

$$(q, w) \vdash_M^* (p, x)$$

bezeichnet.

Akzeptanz und Sprache

Für $w \in \Sigma^*$ startet die Berechnung in (q_0, w). w wird akzeptiert, falls

$$(q_0, w) \vdash_M^* (q_f, \varepsilon) \quad \text{für ein } q_f \in F.$$

Die erkannte Sprache ist

$$L(M) = \{\, w \in \Sigma^* \mid (q_0, w) \vdash_M^* (q_f, \varepsilon) \text{ für ein } q_f \in F \,\}.$$

Nichtdeterministische endliche Automaten

Ein nichtdeterministischer endlicher Automat (NEA) hat dieselbe Struktur

$$M = (Q, \Sigma, \delta, q_0, F)$$

wobei

$$\delta : Q \times \Sigma \to \mathcal{P}(Q)$$

gilt. Damit sind mehrere Folgezustände pro Symbol möglich.
Akzeptanz: Es existiert mindestens ein Lauf, der in einem Zustand aus F endet.

Äquivalenz von DEA und NEA

Sein NEA $N = (Q_N, \Sigma, \delta_N, q_{0N}, F_N)$ kann in einen equivalenten DEA $D = (Q_D, \Sigma, \delta_D, q_{0D}, F_D)$ überführt werden durch

- $Q_D = \mathcal{P}(Q_N)$ (Mengen von NEA-Zuständen),
- $F_D = \{S \subseteq Q_N \mid S \cap F_N \neq \emptyset\}$ (DEA-Endzustände sind Mengen, die mindestens einen NEA-Endzustand enthalten),
- $\delta_D(S, a) = \bigcup_{q \in S} \delta_N(q, a)$ für $S \subseteq Q_N$ und $a \in \Sigma$ (Menge aller Zustände, die durch a von einem Zustand in S erreichbar sind),

ε-Übergänge

ε-NEAs erlauben Übergänge ohne Symbolkonsum mit

$$\delta : Q \times (\Sigma \cup \{\varepsilon\}) \to \mathcal{P}(Q).$$

Auch ε-NEAs sind durch Eliminierung von ε-Übergängen und anschliessende Determinisierung zu DEA äquivalent.

Äquivalenz DEA und RA

Jede von einem DEA erkannte Sprache kann durch einen regulären Ausdruck beschrieben werden, und umgekehrt. Diese Sprachen werden als reguläre bezeichnet. Reguläre Sprachen sind durch verschiedene Formalismen äquivalent beschreibbar, darunter DEA, NEA, ε-NEA und reguläre Ausdrücke.

- **Akzeptierende Mech.:** DEA, NEA, ε-NEA
- **Beschreibungsform:** reguläre Ausdrücke

Abschlusseigenschaften regulärer Sprachen

Die Klasse der regulären Sprachen ist unter verschiedenen Operationen abgeschlossen.
Seien $L, L_1, L_2 \subseteq \Sigma^*$ reguläre Sprachen. Dann sind ebenfalls regulär:

- Vereinigung: $L_1 \cup L_2$
- Konkatenation: $L_1 L_2$
- Kleenesche Hülle: L^*
- Komplement: $\overline{L} = \Sigma^* \setminus L$
- Schnitt: $L_1 \cap L_2$
- Mengendifferenz: $L_1 \setminus L_2$

Zustandsklassen

Zu jedem Zustand p eines Automaten M gehört die Zustandsklasse

$$[p] = \{w \in \Sigma^* \mid M \text{ endet nach dem Lesen von } w \text{ in } p\}.$$

Die Zustandsklassen besitzen folgende Eigenschaften:

- Die Menge aller Wörter wird durch die Klassen partitioniert:
$$\Sigma^* = \bigcup_{p \in Q} [p]$$
- Für verschiedene Zustände sind die Klassen disjunkt:
$$[p] \cap [q] = \emptyset \quad \text{für } p \neq q$$
- Die von M akzeptierte Sprache ergibt sich als Vereinigung der Klassen akzeptierender Zustände:
$$L(M) = \bigcup_{p \in F} [p]$$

Grenzen endlicher Automaten

Ein endlicher Automat hat nur endlich viele Zustände und deshalb nur begrenzten Speicher. Landen zwei Wörter x und y im selben Zustand, kann der Automat sie nicht mehr unterscheiden. Daher gilt für jedes Fortsetzungswort $z \in \Sigma^*$:

$$xz \in L(M) \iff yz \in L(M).$$

Wörter derselben Zustandsklasse verhalten sich also bei jeder Fortsetzung gleich. Damit kann man Mindestzahlen für die benötigten Zustände eines Automaten ableiten.

Kontextfreie Grammatiken

Definition

Eine kontextfreie Grammatik (KFG) ist ein Tupel

$$G = (N, \Sigma, P, S)$$

mit

- Alphabet der **Nichtterminalen** N,
- Alphabet der **Terminalen** Σ mit $N \cap \Sigma = \emptyset$,
- Endliche Menge **Produktionen** $P \subseteq N \times (N \cup \Sigma)^*$,
- **Startsymbol** $S \in N$.

Eine Produktion hat die Form

$$A \to \alpha \quad \text{mit } A \in N,\ \alpha \in (N \cup \Sigma)^*.$$

$\alpha \in (N \cup \Sigma)^*$ wird auch als **Satzformel** bezeichnet.

Ableitung

Der Ableitungsschritt ist definiert durch

$$uAv \Rightarrow_G u\alpha v$$

genau dann, wenn $A \to \alpha \in P$ und $u, v \in (N \cup \Sigma)^*$.
Die reflexiv-transitive Hülle wird mit $\Rightarrow_G^*$ bezeichnet.

Erzeugte Sprache

Die von G erzeugte Sprache ist

$$L(G) = \{\, w \in \Sigma^* \mid S \Rightarrow_G^* w \,\}.$$

Eine Sprache $L \subseteq \Sigma^*$ heisst kontextfrei, falls es eine KFG G mit $L = L(G)$ gibt.

Links- und Rechtsableitung

- **Linksableitung:** In jedem Schritt wird das linkeste Nichtterminal ersetzt.
- **Rechtsableitung:** In jedem Schritt wird das rechteste Nichtterminal ersetzt.

Beide beschreiben dieselbe erzeugte Sprache.

Ableitungsbaum

Ein Ableitungsbaum repräsentiert die hierarchische Struktur einer Ableitung:

- Wurzel ist S.
- Innere Knoten sind Nichtterminale.
- Blätter sind Terminalsymbole.

Die von links nach rechts gelesenen Blätter ergeben das erzeugte Wort.

Mehrdeutigkeit

Eine Grammatik ist mehrdeutig, wenn es ein Wort $w \in L(G)$ mit mindestens zwei verschiedenen Ableitungsbäumen gibt. Eine Sprache heisst inherent mehrdeutig, wenn jede Grammatik, die sie erzeugt, mehrdeutig ist.

Kellerautomaten

Grundidee

Kellerautomaten (KA) erweitern endliche Automaten um einen Stack (Keller) als Speicherstruktur mit LIFO-Zugriff. Sie erkennen genau die Klasse der kontextfreien Sprachen.

Deterministischer Kellerautomat

Ein deterministischer Kellerautomat ist ein Tupel

$$M = (Q, \Sigma, \Gamma, \delta, q_0, \$, F)$$

wobei

- Q eine endliche Menge von Zuständen,
- Σ ein endliches Eingabealphabet,
- Γ ein endliches Kelleralphabet,
- $\delta : Q \times \Sigma \times \Gamma \to Q \times \Gamma^*$ eine Übergangsfunktion,
- $q_0 \in Q$ der Startzustand,
- $\$ \in \Gamma$ das Startkellersymbol,
- $F \subseteq Q$ die Menge der akzeptierenden Zustände.

Damit der Determinismus gewährleistet ist, gilt für jeden Zustand q und alle Symbole $a \in \Sigma$ und $x \in \Gamma$, wenn $\delta(q, a, x)$ definiert ist, dann ist $\delta(q, \varepsilon, x)$ nicht definiert und umgekehrt.

Graphische Darstellung

Der Übergang $\delta(q_0, a, x) = (q_1, w)$ wird grafisch dargestellt als

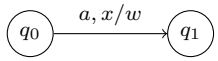

Nichtdeterministischer Kellerautomat

Ein nichtdeterministischer Kellerautomat wird durch den selben Tupel wie der deterministische definiert, jedoch ist die Übergangsfunktion

$$\delta : Q \times (\Sigma \cup \{\varepsilon\}) \times \Gamma \to \mathcal{P}(Q \times \Gamma^*),$$

Konfigurationen

Eine Konfiguration ist ein Tripel

$$(q, w, \gamma) \in Q \times \Sigma^* \times \Gamma^*$$

mit aktuellem Zustand q, Restwort w und Kellerinhalt γ (oberstes Symbol links).

- $(q_0, w, \$)$ ist die Startkonfiguration.
- (q, ε, γ) ist eine Endkonfiguration.

Berechnungsschritt

Ein Schritt

$$(q, aw, X\beta) \vdash_M (p, w, \gamma\beta)$$

ist möglich, falls $(p, \gamma) \in \delta(q, a, X)$ für $a \in \Sigma$.
Ein ε-Schritt

$$(q, w, X\beta) \vdash_M (p, w, \gamma\beta)$$

ist möglich, falls $(p, \gamma) \in \delta(q, \varepsilon, X)$.
Die reflexiv-transitive Hülle wird mit $\vdash_M^*$ bezeichnet.

Akzeptanz

Ein Wort w wird von M akzeptiert, wenn es eine Berechnung gibt, die von der Startkonfiguration $(q_0, w, \$)$ zu einer Endkonfiguration $(q_f, \varepsilon, \gamma)$ mit $q_f \in F$ und $\gamma \in \Gamma^*$ führt:

$$w \in L(M) \iff (q_0, w, \$) \vdash_M^* (q_f, \varepsilon, \gamma)$$

Beziehung zu Grammatiken

Eine Sprache ist kontextfrei genau dann, wenn es einen nichtdeterministischen Kellerautomaten gibt, der sie akzeptiert.

Turingmaschinen

By Justin Iven Müller (2026)
github.com/JustinIven/zhaw-cheatsheets